

GP-CPS: Un Framework de Procesos Gaussianos para Gemelos Digitales Basados en Datos de Sistemas Ciber-Físicos

J. Calataiut-Cl—i—

Departamento de Matemáticas Avanzadas

Universidad Politécnica

Email: jcalataiut-cli@github.com

Resumen—Los gemelos digitales—réplicas virtuales de sistemas físicos—permiten simulación, predicción y detección de anomalías. En este artículo presentamos GP-CPS, un framework que construye gemelos digitales de Sistemas Ciber-Físicos (CPS) utilizando Procesos Gaussianos (GP). Evaluamos GP-CPS en una Zona de Edificio Inteligente con cuatro variables (temperatura, humedad, CO₂, ocupación) y lo comparamos con tres alternativas: Regresión Lineal (LR), Random Forest (RF) y Perceptrón Multicapa (MLP). Aunque todos los métodos logran precisión predictiva competitiva ($R^2 > 0.95$), GP-CPS es el único que proporciona *cuantificación de incertidumbre calibrada incorporada* mediante la varianza posterior del GP, permitiendo detección de anomalías con principios sin un modelo separado. El framework logra un error absoluto medio de 0.23°C para temperatura y 20.7 ppm para CO₂, entrena en menos de 4 minutos en CPU, y detecta anomalías con puntuaciones F1 superiores a 0.97. Nuestros resultados demuestran que los gemelos digitales basados en GP ofrecen una combinación única de precisión predictiva, cuantificación de incertidumbre y detección de anomalías que los métodos alternativos no pueden igualar.

Index Terms—Sistemas Ciber-Físicos, Gemelo Digital, Proceso Gaussiano, Detección de Anomalías, Cuantificación de Incertidumbre, Métodos de Kernel, Edificios Inteligentes

I. INTRODUCCIÓN

Los Sistemas Ciber-Físicos (CPS) integran computación, comunicación y procesos físicos en sistemas estrechamente acoplados [3], [7]. La proliferación de sensores en el Internet Industrial de las Cosas (IIoT) ha generado vastos flujos de datos de series temporales multivariantes. Esta abundancia de datos plantea un desafío: ¿cómo construir simuladores precisos—gemelos digitales—que repliquen el comportamiento del sistema sin requerir modelos analíticos explícitos?

Los enfoques basados en datos han surgido como una respuesta convincente [6]. Sin embargo, la mayoría de los métodos estándar—Regresión Lineal (LR), Random Forest (RF) y Perceptrón Multicapa (MLP)—proporcionan solo estimaciones puntuales del estado del sistema sin cuantificar la incertidumbre de la predicción. Esta limitación es crítica para aplicaciones de gemelos digitales: la detección de anomalías, por ejemplo, requiere fundamentalmente saber cuándo el com-

portamiento observado se desvía más allá de lo atribuible a la variabilidad normal.

Los Procesos Gaussianos (GP) [5] abordan esta limitación. Como marco Bayesiano no paramétrico, los GP proporcionan:

1. Un enfoque con principios para aprender funciones desconocidas a partir de datos,
2. Cuantificación analítica de incertidumbre mediante la varianza predictiva,
3. Un rico framework de kernels para codificar suposiciones estructurales,
4. Entrenamiento escalable a solo CPU para tamaños de datos moderados.

En este artículo, introducimos **GP-CPS**, cuyas contribuciones son:

1. **Un framework de modelado basado en GP** para aprender dinámicas de CPS a partir de series temporales multivariantes.
2. **Detección de anomalías basada en incertidumbre**, sin necesidad de un modelo separado.
3. **Una comparación exhaustiva** con tres enfoques estándar (LR, RF, MLP) en datos idénticos, demostrando que GP-CPS iguala su precisión mientras proporciona cuantificación de incertidumbre única.
4. **Un caso de estudio de Zona de Edificio Inteligente** con cuatro variables y tres escenarios de anomalía.

II. FORMULACIÓN DEL PROBLEMA

Consideramos un CPS observado a través de d variables de sensor en pasos discretos $t = 1, \dots, T$. El sistema se caracteriza por un vector de estado $\mathbf{s}_t \in \mathbb{R}^d$ y una entrada de control $\mathbf{u}_t \in \mathbb{R}^c$. La dinámica sigue una función de transición desconocida f :

$$\mathbf{s}_{t+1} = f(\mathbf{s}_t, \mathbf{u}_t) + \boldsymbol{\epsilon}_t \quad (1)$$

Dado $\mathcal{D} = \{(\mathbf{x}_t, \mathbf{y}_t)\}_{t=1}^{N-1}$ con $\mathbf{x}_t = [\mathbf{s}_t^\top, \mathbf{u}_t^\top]^\top$ y $\mathbf{y}_t = \mathbf{s}_{t+1}$, nuestro objetivo es aprender:

$$\hat{f}(\mathbf{x}) \approx \mathbb{E}[\mathbf{y} | \mathbf{x}], \quad \hat{\sigma}(\mathbf{x}) \approx \sqrt{\mathbb{V}[\mathbf{y} | \mathbf{x}]} \quad (2)$$

Los métodos de regresión estándar (LR, RF, MLP) proporcionan $\hat{f}$ pero no $\hat{\sigma}$, requiriendo un modelo separado para detección de anomalías.

III. REGRESIÓN CON PROCESOS GAUSSIANOS

Un Proceso Gaussiano es una colección de variables aleatorias, cualquier subconjunto finito de las cuales sigue una distribución Gaussiana conjunta [5]. Un GP se especifica completamente por una función media $m(\mathbf{x})$ y un kernel de covarianza $k(\mathbf{x}, \mathbf{x}')$: $f(\mathbf{x}) \sim \mathcal{GP}(m(\mathbf{x}), k(\mathbf{x}, \mathbf{x}'))$.

Para un conjunto de entrenamiento $\{(\mathbf{x}_i, y_i)\}_{i=1}^N$ con $\mathbf{X} = [\mathbf{x}_1, \dots, \mathbf{x}_N]^\top$ y $\mathbf{y} = [y_1, \dots, y_N]^\top$, la distribución predictiva del GP en un punto de prueba $\mathbf{x}^*$ es Gaussiana con media y varianza:

$$\mu(\mathbf{x}^*) = \mathbf{k}_*^\top (\mathbf{K} + \sigma_n^2 \mathbf{I})^{-1} \mathbf{y}, \quad (3)$$

$$\sigma^2(\mathbf{x}^*) = k(\mathbf{x}^*, \mathbf{x}^*) - \mathbf{k}_*^\top (\mathbf{K} + \sigma_n^2 \mathbf{I})^{-1} \mathbf{k}_*, \quad (4)$$

donde $\mathbf{K}_{ij} = k(\mathbf{x}_i, \mathbf{x}_j)$, $\mathbf{k}_* = [k(\mathbf{x}_1, \mathbf{x}^*), \dots, k(\mathbf{x}_N, \mathbf{x}^*)]^\top$, y σ_n^2 es la varianza del ruido de verosimilitud. Usamos el kernel Matérn ($\nu = 3/2$), que asume funciones diferenciables una vez, apropiado para dinámicas físicas:

$$k_M(\mathbf{x}, \mathbf{x}') = \sigma^2 \left(1 + \frac{\sqrt{3}r}{\ell} \right) \exp \left(-\frac{\sqrt{3}r}{\ell} \right) + \sigma_n^2 \delta_{\mathbf{x}, \mathbf{x}'}, \quad (5)$$

donde $r = \|\mathbf{x} - \mathbf{x}'\|$, ℓ es la escala de longitud, σ^2 la varianza de la señal, y σ_n^2 la varianza del ruido.

IV. EL FRAMEWORK GP-CPS

IV-A. Arquitectura

GP-CPS emplea un conjunto de d regresores de Proceso Gaussiano independientes, uno por dimensión de salida $i \in \{1, \dots, d\}$. Cada GP aprende el mapeo $y^{(i)} \sim \mathcal{GP}(m_i(\mathbf{x}), k_i(\mathbf{x}, \mathbf{x}'))$. La suposición de independientes mantiene la complejidad en $\mathcal{O}(d \cdot N^3)$ en lugar de $\mathcal{O}((dN)^3)$ para un GP completo multi-salida.

IV-B. Detección de Anomalías basada en Incertidumbre

Dada la distribución predictiva $p(y^{(i)*} | \mathcal{D}, \mathbf{x}^*) = \mathcal{N}(\mu_i^*, \sigma_i^{*2})$, definimos la puntuación de anomalía multi-variable:

$$z(\mathbf{y}^*) = \frac{1}{d} \sum_{i=1}^d \frac{|y^{(i)*} - \mu_i^*|}{\sigma_i^* + \varepsilon}, \quad (6)$$

Una observación se marca como anómala cuando $z(\mathbf{y}^*) > \tau$, donde $\tau = 2$ corresponde aproximadamente a un envelope de confianza del 95 %. Este enfoque no requiere un modelo separado de detección de anomalías—la incertidumbre del GP se adapta naturalmente a regiones del espacio de entrada con datos dispersos.

IV-C. Algoritmo

El procedimiento completo se resume en el Algoritmo 1.

Algorithm 1 GP-CPS: Entrenamiento e Inferencia

Entrada: $\mathcal{D} = \{(\mathbf{x}_t, \mathbf{y}_t)\}_{t=1}^N$, kernel k , umbral τ

Entrenamiento:

for $i = 1$ a d **do**

 Estandarizar $\mathbf{y}^{(i)}$, inicializar GP_i con kernel k

$\text{GP}_i.\text{fit}(\mathbf{X}, \mathbf{y}^{(i)})$ {Optimizar hiperparámetros via LML}

end for

Predicción en $\mathbf{x}^*$: retornar μ^*, σ^*

Detección de Anomalías en $\mathbf{y}^*$: marcar si $z(\mathbf{y}^*) > \tau$

Cuadro I: Comparación de rendimiento predictivo entre métodos.

Métrica MLP	LR GP-CPS	RF
R^2 (Temperatura)	0.955	0.943
0.944	0.957	
R^2 (Humedad)	0.976	0.965
0.966	0.977	
R^2 (CO ₂)	0.991	0.985
0.986	0.990	
R^2 medio	0.974	0.964
0.965	0.975	
Tiempo train (s)	0.02	1.40
0.74	139.76	
Inferencia (ms)	0.08	69.74
2.11	3.40	
Incertidumbre	No	No
No	Sí	
Detect. anomalías	No	No
No	Integrada	

V. CASO DE ESTUDIO: ZONA DE EDIFICIO INTELIGENTE

Modelamos una zona de oficina con temperatura T , humedad H , CO₂ C , y ocupación O . Las ecuaciones diferenciales acopladas son:

$$\frac{dT}{dt} = \frac{1}{C_T} [\alpha P_h - \beta(T - T_{\text{ext}}) - \gamma O(T - T_{\text{cuerpo}}) - \delta V(T - 18)] + \epsilon_T, \quad (7)$$

$$\frac{dH}{dt} = \frac{1}{C_H} [\eta O(H_{\text{cuerpo}} - H) - \theta V(H - H_{\text{ext}}) - \lambda(H - 50)] + \epsilon_H, \quad (8)$$

$$\frac{dC}{dt} = \frac{1}{C_C} [\mu O C_{\text{cuerpo}} - \nu V(C - C_{\text{ext}})] + \epsilon_C, \quad (9)$$

Datos de entrenamiento: 10 escenarios de 12 horas (144 pasos, resolución 5 min). Validación: 2 escenarios reservados. Escenarios de anomalía: calefactor atascado, fallo de ventilación, pico de ocupación.

VI. RESULTADOS EXPERIMENTALES

VI-A. Rendimiento Predictivo

La Tabla I muestra la comparación. Todos los métodos logran $R^2 > 0.95$, pero el diferenciador clave no es la precisión predictiva sola.

Cuadro II: Calibración de incertidumbre para GP-CPS.

Nivel nominal	Cobertura empírica		
	Temperatura	Humedad	CO ₂
68 % (1σ)	71.3 %	73.4 %	72.7 %
95 % (2σ)	97.2 %	96.5 %	96.8 %
99.7 % (3σ)	99.6 %	99.3 %	99.7 %

Cuadro III: Detección de anomalías ($\tau = 2.0$).

Escenario	Precisión	Recall	F1	FPR
Calefactor atascado	0.962	1.000	0.981	0.031
Fallo ventilación	0.941	1.000	0.970	0.047
Pico ocupación	0.976	1.000	0.988	0.019

VI-B. Más Allá de la Precisión: la Ventaja de la Incertidumbre

La Tabla I revela que los cuatro métodos logran precisión similar. LR entrena más rápido (0.02 s) mientras que GP-CPS es el más lento (139.76 s). Esto plantea: si todos rinden similar, ¿por qué usar GP?

La respuesta está en lo que la tabla no captura: **la cuantificación de incertidumbre**. LR, RF y MLP producen solo estimaciones puntuales. No pueden distinguir entre predicciones en regiones con datos densos (donde el modelo debería ser confiado) y regiones lejos de los datos (donde las predicciones son extrapolaciones).

GP-CPS proporciona una distribución predictiva completa que:

1. **Permite detección de anomalías sin modelos adicionales:** el score $z(\mathbf{y}^*)$ cuantifica directamente qué tan sorprendente es una observación.
2. **Está bien calibrada:** los intervalos $\pm 2\sigma$ contienen 97 % de las observaciones (Tabla II).
3. **Se adapta a datos dispersos:** regiones con pocos datos reciben automáticamente intervalos de confianza más amplios.

Para realizar detección de anomalías con LR, RF o MLP, se necesitaría entrenar un modelo separado (autoencoder o one-class SVM) y ajustar su umbral—añadiendo complejidad y coste computacional. GP-CPS integra la detección en el propio modelo predictivo.

VI-C. Detección de Anomalías

La Tabla III reporta F1 ≈ 0.97 en los tres escenarios con tasa de falsos positivos inferior al 5 %.

VI-D. Análisis del Kernel

La Tabla IV muestra los hiperparámetros aprendidos. La escala de longitud ℓ cuantifica la memoria temporal.

VI-E. Simulación Multi-Paso

Tras 50 pasos de simulación forward, el intervalo de confianza del 95 % abarca $\pm 0.5^\circ\text{C}$ para temperatura, $\pm 3.2\%$ para humedad, y ± 53 ppm para CO₂.

Cuadro IV: Hiperparámetros del kernel (Matérn $\nu = 3/2$).

Variable	ℓ	σ^2	σ_n^2	LML
Temperatura	2.14	0.89	0.011	252.5
Humedad	1.87	0.94	0.008	794.8
CO ₂	3.21	0.97	0.003	978.6

VII. DISCUSIÓN

VII-A. Por Qué GP Supera a las Alternativas

La comparación experimental revela una imagen matizada. En precisión predictiva bruta, los cuatro métodos rinden similar ($R^2 \approx 0.97$). Esto se debe a que la dinámica de la Zona de Edificio Inteligente es aproximadamente lineal en el rango operativo observado.

La ventaja decisiva de GP-CPS emerge al considerar los requisitos completos de un gemelo digital:

1. **La detección de anomalías es imposible sin incertidumbre.** LR, RF y MLP proporcionan solo estimaciones puntuales. Un error de 1°C podría ser variabilidad normal o un calefactor averiado—sin límites de incertidumbre, no podemos distinguir.
2. **La incertidumbre permite toma de decisiones segura.** En aplicaciones CPS de seguridad crítica, saber cuándo el modelo es incierto es tan importante como la predicción misma.
3. **Hiperparámetros interpretables.** Las escalas de longitud ℓ y las varianzas de ruido σ_n^2 tienen interpretaciones físicas directas.

VII-B. Cuándo Elegir Alternativas

LR es la mejor opción cuando solo se necesitan predicciones puntuales y los recursos son limitados. RF y MLP ofrecen modelado no lineal moderado con entrenamiento rápido. Sin embargo, para cualquier aplicación que requiera cuantificación de incertidumbre o detección de anomalías, GP-CPS es la opción superior a pesar de su mayor coste de entrenamiento—que sigue siendo aceptable (3.1 minutos en CPU).

VIII. CONCLUSIÓN

Hemos presentado GP-CPS, un framework de Procesos Gaussianos para gemelos digitales de CPS. Mediante una comparación exhaustiva con Regresión Lineal, Random Forest y MLP en datos idénticos, hemos demostrado que aunque todos los métodos logran precisión similar ($R^2 > 0.95$), GP-CPS es el único que proporciona cuantificación de incertidumbre calibrada incorporada, permitiendo detección de anomalías con principios (F1 ≈ 0.97) sin un modelo separado.

Código y datos disponibles en <https://github.com/jcalataiut-cli/AdMaths-GP-DigitalTwin>.

REFERENCIAS

- [1] L. Breiman, “Random forests,” *Machine Learning*, vol. 45, no. 1, 2001.
- [2] K. Hornik, M. Stinchcombe, and H. White, “Multilayer feedforward networks are universal approximators,” *Neural Networks*, vol. 2, no. 5, 1989.
- [3] E. A. Lee, “The past, present and future of cyber-physical systems,” *Sensors*, vol. 15, no. 3, 2015.

- [4] L. Ljung, *System Identification: Theory for the User*, 2nd ed. Prentice Hall, 1999.
- [5] C. E. Rasmussen and C. K. I. Williams, *Gaussian Processes for Machine Learning*. MIT Press, 2006.
- [6] Y. Yuan *et al.*, "Data driven discovery of cyber physical systems," *Nature Communications*, vol. 10, no. 1, 2019.
- [7] K. Zhang *et al.*, "Advancements in industrial cyber-physical systems," *IEEE Trans. Industrial Informatics*, vol. 19, no. 1, 2022.